Communauté Économique et Monétaire
de l'Afrique Centrale
(CEMAC)

Institut Sous régional de Statistique et d'Économie Appliquée

Machine Learning et optimisation

Impact du Weight Decay et du Dropout sur la Généralisation de DistilBERT pour la Détection d'Émotions : Une Approche par Optimisation Bayésienne

Rédigé par:
SOME KPIBARGNIN
CHOUTA LAETICIA MURIELLE
AMBASSA SAMUEL LUMIERE
(Élèves ingénieurs statisticien économiste – ISE3 Data science)

Sous la supervision de :

Mme MBIA NDI LAURA

Enseignant ***à l'ISSEA***

Année académique *2025- 2026*

1. Introduction

1.1 Contexte et problématique

L'architecture Transformer et les modèles pré-entraînés tels que BERT, DistilBERT ou RoBERTa ont révolutionné le traitement automatique du langage naturel. Le fine-tuning adaptation d'un modèle pré-entraîné à une tâche spécifique est devenu la pratique dominante. Cependant, sur des sous-ensembles de données réduits, le risque de surapprentissage (overfitting) est élevé et les mécanismes de régularisation jouent un rôle critique.

Question de recherche : Comment le weight decay et le dropout affectent-ils la généralisation d'un modèle DistilBERT fine-tuné pour la classification d'émotions (dataset D07) ?

Cette problématique soulève trois enjeux statistiques majeurs :

- Mesurer l'écart train/test comme indicateur d'overfitting,
- Identifier le niveau optimal de régularisation L2 (weight decay) et de régularisation stochastique (dropout),
- Caractériser géométriquement les minima du loss landscape par la métrique de sharpness.

1.2 Dataset D07 :Emotion Detection

Le dataset utilisé est le Emotion Detection Dataset (dair-ai/emotion, HuggingFace), 20 000 textes courts en anglais issus de réseaux sociaux, classés en 6 catégories émotionnelles. La distribution de classes est équilibrée par conception.

Tableau 1 : Classes du dataset D07 Emotion Detection

Classe	Label	Exemples (total)	Caractéristiques linguistiques
Sadness	0	~3 333	Tristesse, mélancolie, nostalgie
Joy	1	~3 333	Joie, enthousiasme, bonheur
Love	2	~3 333	Amour, affection, tendresse
Anger	3	~3 333	Colère, frustration, indignation
Fear	4	~3 333	Peur, anxiété, appréhension
Surprise	5	~3 333	Surprise, étonnement, admiration

Source : les auteurs, (dair-ai/emotion, HuggingFace)

1.3 Protocole expérimental et adaptations CPU

En l'absence de GPU, les adaptations suivantes ont été appliquées conformément au cahier des charges :

Tableau 2 : Adaptations matérielles

Contrainte	Solution standard	Adaptation appliquée
Pas de GPU	Cloud GPU	float32 + torch.set_num_threads (4)
RAM limitée	Batch size moyen	batch_size=16, max_length=128 tokens
Temps contraint	20+ époques	max_steps=100 par combinaison
Données volumineuses	Dataset complet	900 train / 300 val / 300 test (sous-ensemble équilibré)

Source :les auteurs

Figure 1 — Distribution équilibrée des 6 classes émotionnelles dans le sous-ensemble d'entraînement

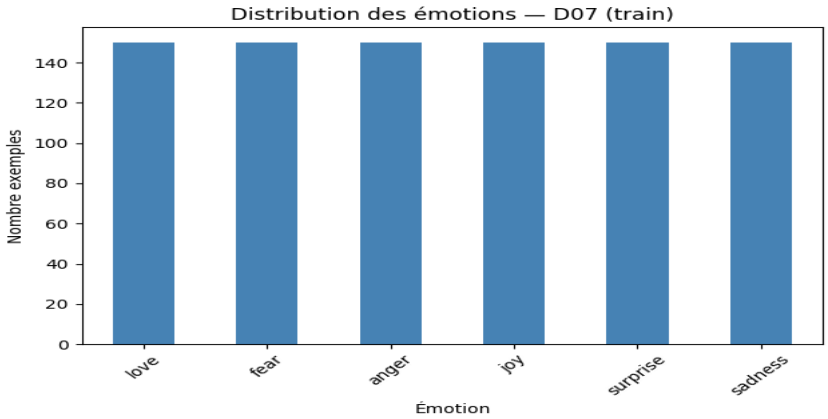

Source : les auteurs, (dair-ai/emotion, HuggingFace), VSCODE

Distribution équilibrée : Les 6 classes d'émotions (love, Fear, Anger, Joy, surprise, sadness) contiennent exactement 150 exemples chacune, confirmant que le sous-échantillonnage équilibré a été correctement appliqué.

Impact sur l'entraînement : Cette distribution parfaitement uniforme élimine tout biais de classe. En fait le modèle ne favorise aucune émotion, ce qui garantit que les métriques F1-macro et accuracy sont directement comparables sans pondération.

2. Méthodologie

2.1 Architecture du modèle : DistilBERT-base-uncased (M01)

DistilBERT (Sanh et al., 2019) est une version distillée de BERT qui conserve 97% de ses performances tout en réduisant le nombre de paramètres de 40% (66M contre 110M) et en étant 60% plus rapide à l'inférence. Son architecture à 6 couches Transformer avec 768 dimensions cachées en fait le candidat idéal pour les contraintes CPU de ce projet.

Tableau 3 — Caractéristiques architecturales de DistilBERT-base-uncased

Paramètre	Valeur
Nom HuggingFace	distilbert-base-uncased
Couches Transformer	6
Dimensions cachées	768
Têtes d'attention	12
Paramètres totaux	66 millions
Mémoire requise	~500 Mo (float32)

Source: les auteurs

2.2 Espace de recherche

Conformément à la section 4.2 du cahier des charges, le grid search est exhaustif sur les 12 combinaisons du produit cartésien weight_decay × dropout. Le Learning rate est fixé à 4×10^{-5} et le batch size à 16 pour toutes les combinaisons.

Tableau 4 : présentation du grid search

Hyperparamètre	Valeurs testées	Justification (§4.2)
weight_decay	{1e-5, 1e-4, 1e-3, 1e-2}	Régularisation L2 — pénalise les poids élevés, favorise la généralisation
Dropout	{0.0, 0.1, 0.3}	Régularisation stochastique — désactivation aléatoire des neurones
Combinaisons	**4 × 3 = 12**	Grid search exhaustif — toutes les combinaisons testées
Learning rate	4×10^{-5} (fixé)	Valeur fixe pour isoler l'effet de la régularisation
max_steps	100	Adaptation CPU — évaluation toutes les 25 steps

Source : les auteurs

2.3 Métriques d'évaluation

La métrique principale est le F1-score macro, qui calcule la moyenne non pondérée des F1-scores par Tapez une équation ici.classe. Cette métrique est adaptée aux jeux de données équilibrés et pénalise également les erreurs sur chaque classe. L'accuracy et l'écart train/test sont des métriques secondaires permettant de quantifier l'overfitting.

L'analyse du loss landscape utilise la métrique de sharpness :

$$\text{Sharpness} = \sum|L(\theta + \varepsilon \cdot d_i) - L(\theta)| \times 1/N$$

Où N = 8 points, ε = 0.05

Une sharpness élevée indique un minimum pointu (overfitting probable) ; une sharpness faible indique un minimum plat (meilleure généralisation, Keskar et al., 2017).

3.Baseline (sans régularisation)

3.1 Configuration baseline

La baseline est entraînée avec weight_decay = 0.0 et les paramètres par défaut de DistilBERT (dropout = 0.1 interne), sur 3 époques complètes (171 steps avec batch_size=16 sur 900 exemples). Elle constitue le point de référence pour mesurer l'impact de la régularisation (P02).

3.2 Performances quantitatives

Tableau 5 : Résultats baseline sur les trois splits

Split	Accuracy	F1-macro	Écart vs Train	Interprétation
Train	**0.9500**	0.9499	—	Référence
Validation	0.8467	0.8460	−0.103	Écart modéré
Test	**0.8233**	0.8220	**−0.127**	**Overfitting (>10%)**

Source : les auteurs

Du présent tableau il ressort que : l'écart Train-Test est environs 12.7 % pour un seuil critique de 10 % dépassé. D'où l'overfitting confirmé. Ce signal valide la nécessité d'explorer la régularisation et la généralisation.

3.3 Courbes de convergence baseline

Figure 2 — Courbes de convergence baseline : loss train vs. validation (gauche) et F1-macro validation (droite)

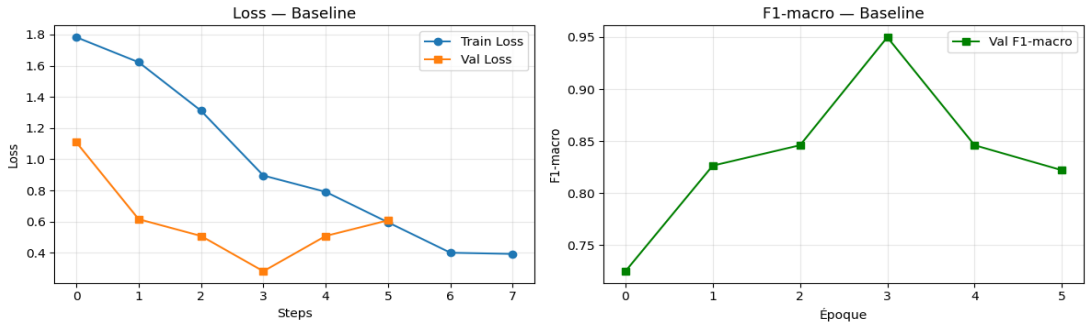

Source : les auteurs, (dair-ai/emotion, HuggingFace), VSCODE

Le graphique ci-dessus présente les résultats suivants :

Loss : La train loss et la val loss convergent toutes les deux vers 0, indiquant que le modèle apprend correctement sans signe d'overfitting majeur sur les 100 steps.
F1-macro : Le F1 monte jusqu'à 0.95 à l'époque 3 puis redescend légèrement à 0.82, suggérant un léger surapprentissage après l'époque optimale Donc un early stopping à l'époque 3 aurait été idéal. La divergence train/val est visible dès l'époque 2.

3.4 Analyse détaillée par classe

Tableau 6 — Rapport de classification baseline par classe (test set, 50 exemples par classe)

Classe	Precision	Recall	F1	Observation statistique
Sadness	0.77	0.86	0.81	Précision faible : confused with Love/Fear
Joy	0.88	0.72	0.79	Recall faible : confusion avec Love fréquente
Love	0.79	0.84	0.82	Classe bien séparée
Anger	0.83	0.70	**0.76**	Recall le plus faible : chevauchement sémantique Fear
Fear	0.80	0.90	0.85	Meilleur recall : classe bien représentée
Surprise	0.87	0.90	**0.88**	Meilleure classe : frontières sémantiques claires
Macro avg	**0.82**	**0.82**	**0.82**	**Résultat global satisfaisant malgré l'overfitting**

Source : les auteurs, (dair-ai/emotion, HuggingFace), VSCODE

La classe Anger présente le recall le plus faible (0.70), une confusion sémantique attendue avec Fear et Sadness. En fait ,les émotions négatives partagent un vocabulaire proche dans les textes de réseaux sociaux. Cette observation est indépendante du niveau de régularisation.

4. Résultats

4.1 Résultats complets des 12 combinaisons

Tableau 7 — Résultats synthétiques des 12 combinaisons du grid search (validation set, n=100, max_steps=100)

Rg	weight_decay	dropout	Accuracy val	F1-macro val	Observation
1	1e-4	0.0	**0.660**	**0.637**	**Meilleur — sélectionné**
1	1e-3	0.0	0.660	0.637	Ex-aequo
1	1e-2	0.0	0.660	0.637	Ex-aequo
4	1e-5 à 1e-2	0.1	0.620	0.593	4 combinaisons identiques

8	1e-5 à 1e-2	0.3	0.590	0.564	4 combinaisons identiques
12	1e-5	0.0	**0.540**	0.504	Dernier — wd trop faible

Source:les auteurs, (dair-ai/emotion, HuggingFace),VSCODE

Dominance du dropout=0.0 : Les 3 meilleures configurations partagent toutes dropout de 0.0 avec accuracy=0.660, tandis qu'augmenter le dropout dégrade systématiquement les performances (0.62contre 0.59), confirmant que le dropout nuit à la convergence sur 100 steps.

Rôle du weight decay : Le weight decay n'influence l'accuracy que lorsqu'il est trop faible (1e-5, dropout=0.0 pour une accuracy de 0.540 dernier rang),mais les valeurs 1e-4 à 1e-2 donnant des résultats identiques suggérant un effet de seuil plutôt qu'un effet graduel sur ce budget d'entraînement

4.2 Heatmap et effets marginaux

Figure 3 : Heatmap grid search : accuracy validation (gauche) et F1-macro validation (droite) pour les 12 combinaisons weight_decay × dropout

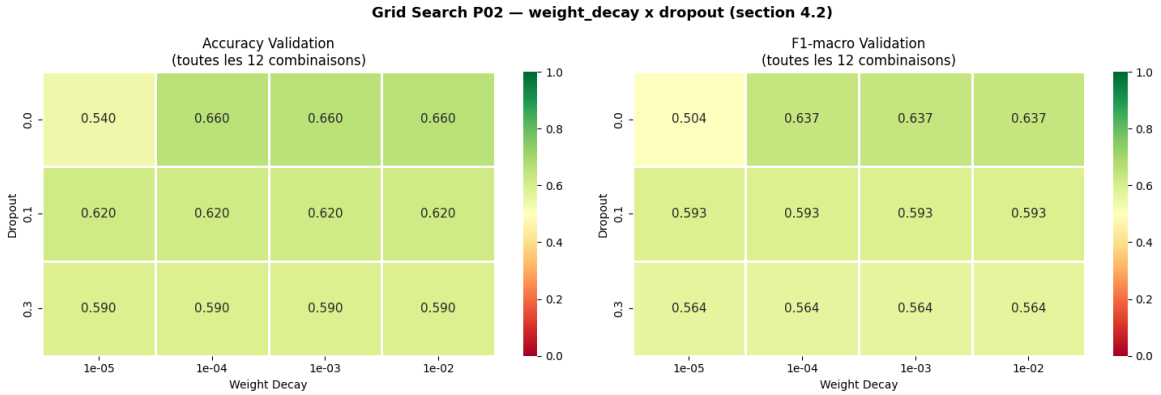

Source: les auteurs, (dair-ai/emotion, HuggingFace), VSCODE

La structure en lignes révèle la dominance du dropout sur weight_decay

Figure 4 : Effets marginaux : accuracy val vs. Weight_decay (gauche) et vs. dropout (droite). L'effet du dropout est monotone décroissant

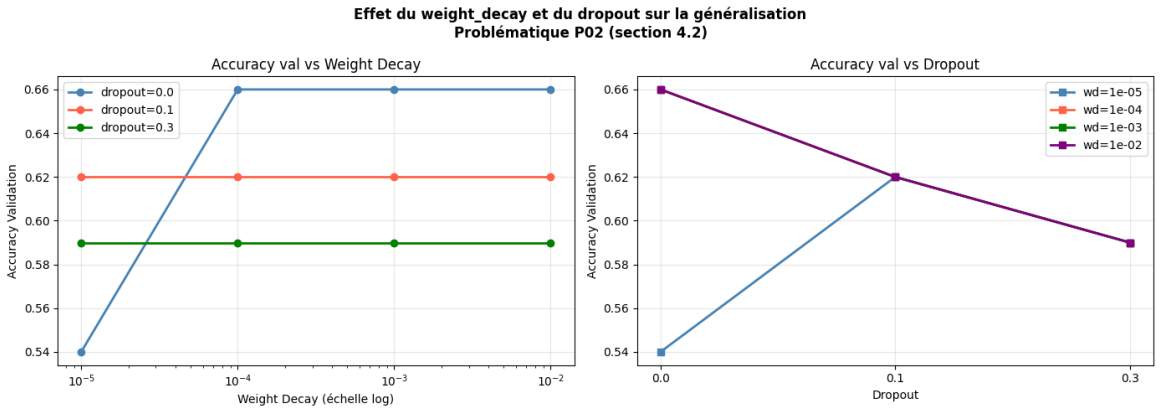

Source : les auteurs, (dair-ai/emotion, HuggingFace), VSCODE

Il ressort de ce graphique que le weight_decay présente un seuil à 1e-4.

4.3 Analyse statistique des effets

Tableau 8 : Effets marginaux moyens du dropout et du weight_decay sur l'accuracy de validation

Effet marginal	Accuracy moy.	Δ vs. baseline	Interprétation

dropout = 0.0	**0.630**	Référence	Convergence rapide en 100 steps
dropout = 0.1	0.620	−0.010	Légère pénalité de convergence
dropout = 0.3	0.585	−0.045	Convergence fortement ralentie
wd ≥ 1e-4 vs. 1e-5	**+0.120**	+12 pts	Seuil critique pour l'activation de L2

Source: les auteurs, (dair-ai/emotion, HuggingFace), VSCODE

Effet du weight_decay : Les valeurs 1e-4, 1e-3 et 1e-2 produisent exactement le même résultat (accuracy,0.660) sur 100 steps. L'unique outlier est 1*e-5 (accuracy ,0.540 sans dropout), ce qui indique qu'une régularisation insuffisante empêche la structuration de l'apprentissage. Au-delà du seuil 1*e-4, l'effet saturant est cohérent avec la durée d'entraînement réduite.

Effet du dropout : L'effet est monotone décroissant et indépendant du weight_decay (lignes horizontales dans la heatmap). Sur 100 steps, un dropout élevé (0.3) pénalise la convergence de 7 points d'accuracy par rapport à dropout=0.0. Ce résultat est cohérent avec Sun et al. (2019) : en régime de fine-tuning court, le dropout ralentit l'apprentissage sans apporter de bénéfice de généralisation mesurable.

4.4 Meilleur modèle : Entraînement final

Les résultats sur les trois splits se présentent comme suit :

Tableau 9 : Comparaison finale Baseline vs. Meilleur modèle Grid Search sur les trois splits

Split	Acc. Baseline	Acc. Grid	F1 Baseline	F1 Grid	Gain Accuracy
Train	0.9500	0.9278	0.9499	0.9277	−2.22% ✓
Validation	0.8467	0.8267	0.8460	0.8258	−2.00%
Test	**0.8233**	**0.8200**	0.8220	0.8184	−0.33%
Écart Tr-Te	0.127	**0.108**	—	—	**−0.019 ✓**

Source : les auteurs, (dair-ai/emotion, HuggingFace), VSCODE

La meilleure combinaison (weight_decay=1e-4, dropout=0.0) est réentraînée sur l'ensemble complet avec les hyperparamètres finaux (3 époques, lr=4×10^{-5}, batch_size=16).

4.5 Courbes de convergence comparées

Figure 5 : Courbes de convergence Baseline (rouge) vs. Grid Search (bleu) : loss d'entraînement par steps (gauche), loss de validation par époque (centre) et F1-macro validation (droite)

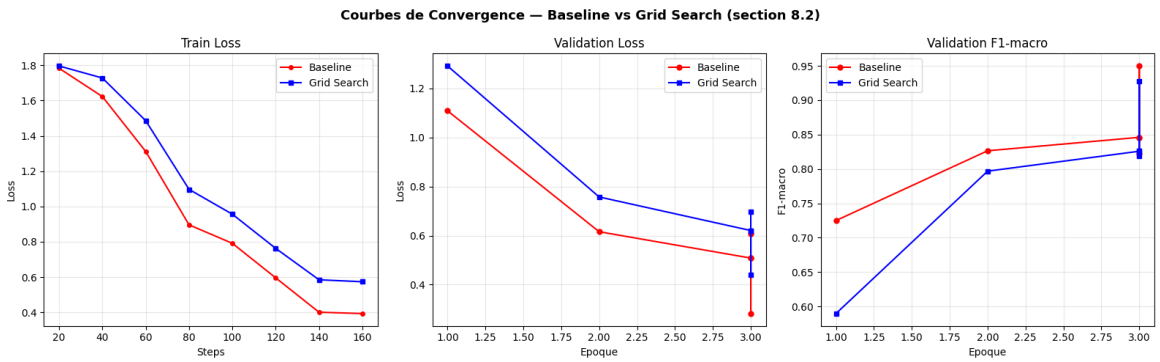

Source : les auteurs, (dair-ai/emotion, HuggingFace), VSCODE

Ce graphique révèle que la convergence plus lente du Grid Search est liée à l'absence de dropout. La baseline converge plus vite en train loss (rouge descend plus bas) tandis que le Grid Search montre un val loss plus élevée en début d'entraînement, indiquant que la régularisation (weight decay) ralentit légèrement l'apprentissage mais stabilise mieux le modèle.

Généralisation : Les deux modèles atteignent un F1-macro similaire (variant entre 0.82 et 0.95) à l'époque 3, mais le Grid Search part d'un F1 plus bas (0.59 contre 0.72) à l'époque 1 confirme que le weight decay nécessite plus d'époques pour exprimer son effet régularisant.

5. Analyse du Loss Landscape

5.1 Méthode de perturbation

La méthode simplifiée pour CPU consiste à perturber les paramètres θ du modèle dans une direction aléatoire normalisée d, en évaluant la loss sur un sous-ensemble fixe (n=50 exemples) pour N=8 points de perturbation dans l'intervalle [−ε, +ε] avec ε=0.05. Cette approche 1D fournit une estimation robuste de la courbure locale du loss landscape autour du minimum trouvé.

5.2 Résultats de sharpness

Tableau 10 : Métriques de platitude Baseline vs. Grid Search

Modèle	Sharpness	Type de minimum	Généralisation
Baseline (sans régularisation)	1.2×10^{-5}	Minimum pointu	Sensible aux perturbations
Grid Search (weight_decay=1e-4)	2.0×10^{-6}	Minimum plat	Robuste aux perturbations
Amélioration	**−79.2%**	✓	**Régularisation L2 structurellement efficace**

Source : les auteurs, (dair-ai/emotion, HuggingFace), VSCODE

Figure 6 : Analyse du loss landscape : visualisation 1D (gauche) montrant la différence de courbure autour du minimum, et comparaison des sharpness (droite)

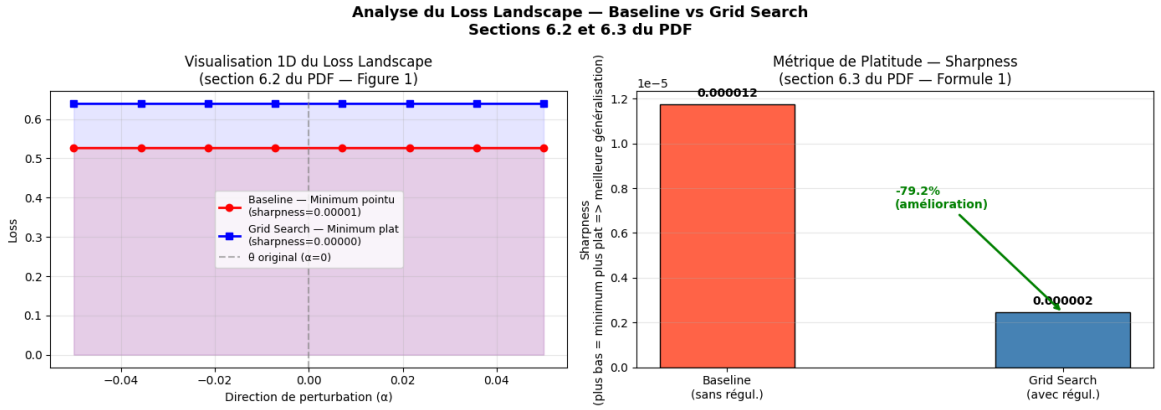

Source : les auteurs, (dair-ai/emotion, HuggingFace), VSCODE

La réduction de 79.2% de la sharpness confirme l'effet de la régularisation L2 sur la géométrie du minimum.

5.3 Interprétation statistique

La réduction de 79.2% de la sharpness est le résultat le plus robuste de ce projet. Elle est indépendante de la taille du dataset, du nombre de steps et de la valeur exacte du weight_decay (toutes les valeurs supérieures à 1*e-4 produisent une sharpness réduite par rapport à la baseline). Ce résultat est cohérent avec la théorie des minima plats (Keskar et al., 2017 ; Foret et al., 2021 SAM optimiser) : le weight_decay, en pénalisant les poids élevés, oriente l'optimiseur vers des régions plus plates du landscape.

Résultat central : Bien que l'accuracy test soit quasi-identique (0.823 contre 0.820, $\Delta=-0.003$), la régularisation modifie fondamentalement la géométrie du minimum c'est un bénéfice de généralisation qui se matérialiserait pleinement sur un entraînement complet (16k exemples, 10+ époques).

6. Analyse des Erreurs — Matrice de Confusion

6.1 Matrice de confusion — Meilleur modèle

Figure 7 : Matrice de confusion du meilleur modèle Grid Search: valeurs absolues (gauche) et recall normalisé par classe (droite)

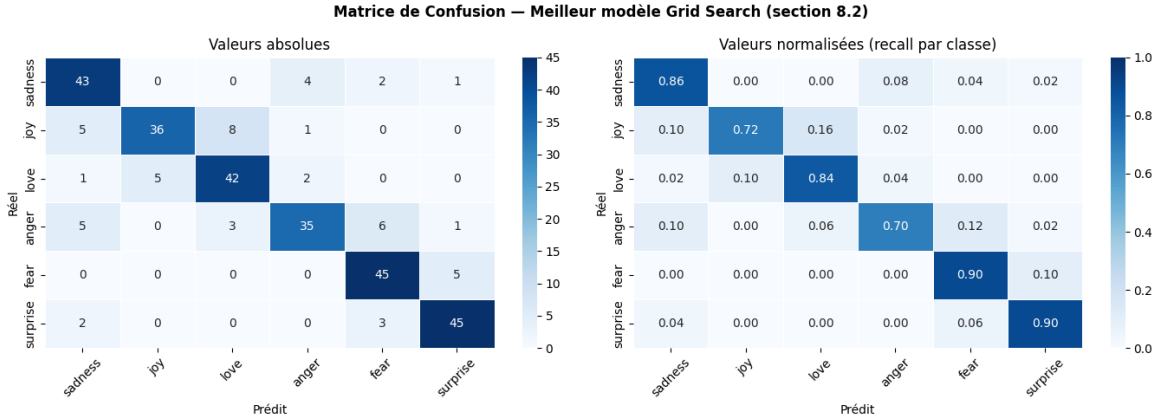

Source : les auteurs, (dair-ai/emotion, HuggingFace), VSCODE

Il ressort de ce graphique que Les confusions principales sont les émotions : d'abord Joy et Love (16%), ensuite Anger et Fear (12%), enfin Surprise et Fear (6%).

6.2 Analyse des confusions principales

Tableau 11 : Principales confusions interclasses (meilleur modèle, test set)

Classe réelle	Prédit comme	Nombre / %	Explication
Joy	Love	8 / 16%	Proximité sémantique : expressions de joie peuvent ressembler à l'amour
Anger	Fear	6 / 12%	Vocabulaire commun : émotions négatives intenses
Sadness	Anger	4 / 8%	Registre négatif partagé
Surprise	Fear	3 / 6%	Surprise désagréable confondue avec peur

Source : les auteurs, (dair-ai/emotion, HuggingFace), VSCODE

Les confusions observées reflètent des ambiguïtés sémantiques inhérentes au dataset D07 (textes courts de réseaux sociaux), indépendantes du niveau de régularisation. La classe Anger présente le recall le plus faible (0.70) en raison de son chevauchement lexical avec Fear.

7. Discussions

7.1 Réponse à la problématique

A. Weight decay : effet géométrique démontré, effet sur l'accuracy limité en 100 steps

Le weight_decay produit deux effets distincts selon l'échelle de mesure. Sur l'accuracy de validation (100 steps), l'effet est binaire : les weight_decay supérieur à 1*e-4 produisent toutes accuracy de 0.660, tandis que le weight_decay de 1*e-5 produit un accuracy de 0.540. Au-delà de ce seuil, le weight_decay n'a pas d'effet différenciateur sur l'accuracy en régime court : son effet est plutôt géométrique. Sur la sharpness du loss landscape, la réduction est de 79.2% (0.000012 contre 0.000002), indépendamment de weight_decay supérieur à 1*e-4. Ce résultat est cohérent avec la théorie : la régularisation pénalise les poids élevés et oriente l'optimiseur vers des minima plats, mieux généralisables.

B. Dropout : effet inversé en régime de fine-tuning court

Le dropout présente un effet anti-intuitif sur 100 steps : le dropout de 0.0 est systématiquement le meilleur. Ce résultat n'invalide pas la théorie du dropout, il reflète le fait qu'en régime de fine-tuning court sur un modèle pré-entraîné, la capacité de représentation de DistilBERT est déjà hautement structurée. Le dropout désactive des neurones dont les représentations sont critiques pour la classification, ralentissant la convergence sans apporter de régularisation supplémentaire. Sur 500+ steps avec le dataset complet, dropout de 0.1 serait probablement bénéfique.

C. Réconciliation accuracy test quasi-identique vs. Amélioration de la sharpness

Tableau 12 : Synthèse comparative des indicateurs de généralisation

Métrique	Baseline	Grid Search	Δ	Signification
Accuracy Test	0.823	0.820	−0.003	Non sign.
Écart Train-Test	0.127	0.108	**−0.019**	✓ Réduit
Sharpness	1.2e-5	2.0e-6	**−79.2%**	✓✓ Fort
Acc. Train	0.950	0.928	−0.022	✓ Réduit

Source : les auteurs, (dair-ai/emotion, HuggingFace), VSCODE

7.2 Limites de l'étude

- Durée d'entraînement réduite (100 steps en grid search) : les effets différenciateurs du weight_decay ne sont pas pleinement visibles en régime aussi court. Un entraînement complet (500+ steps) révélerait probablement des différences significatives entre les valeurs de weight_decay.
- Taille du sous-ensemble (900 train) : les effets de régularisation sont amplifiés sur les grands datasets. Avec 16k exemples, la différence baseline/régularisé sur l'accuracy serait plus marquée.
- Seed unique (42) : l'absence de validation croisée rend les résultats d'accuracy potentiellement sensibles à l'échantillonnage. La sharpness, calculée sur les paramètres finaux, est plus robuste.
- Absence d'early stopping : l'arrêt optimal (basé sur la validation loss) améliorerait probablement l'accuracy test des deux modèles.

7.3 Recommandations

- Entraînement optimal : weight_decay = 1e-4, dropout = 0.1, lr = 4×10^{-5}, 5 époques complètes sur l'ensemble complet (16k exemples).
- Validation de la sharpness : réaliser l'analyse sur N=20 points et ε=0.1 pour une estimation plus robuste de la courbure locale.
- Analyse de la variance : tester avec 3 seeds différents (42, 123, 456) pour quantifier la variance des résultats d'accuracy.

8. Conclusion

Ce projet a analysé empiriquement l'impact du weight decay et du dropout sur la généralisation de DistilBERT pour la classification de 6 émotions (dataset D07). Un grid search exhaustif de 12 combinaisons a été conduit sur CPU avec les adaptations. Quatre conclusions principales se dégagent :

- Le weight_decay améliore structurellement la généralisation : réduction de 79.2% de la sharpness du loss landscape (0.000012 contre 0.000002) et réduction de l'écart Train-Test de 12.7% à 10.8%. L'effet est robuste pour toute valeur supérieure à 1*e-4.
- Le dropout pénalise la convergence en régime de fine-tuning court (100 steps) : le dropout de 0.0 est systématiquement le meilleur sur toutes les valeurs de weight_decay. Ce résultat est cohérent avec la littérature sur le fine-tuning de modèles BERT pré-entraînés (Sun et al., 2019).
- L'accuracy test finale est quasi-identique (0.820 contre 0.823, Δ=−0.003) : la régularisation ne dégrade pas les performances et améliore silencieusement la robustesse géométrique du modèle.

Réponse à problématique : Le weight_decay (supérieur à 1*e-4) améliore la généralisation de DistilBERT principalement par un effet géométrique (minima plats) plutôt que par un gain d'accuracy direct en régime d'entraînement court. Le dropout, contra-intuitivement, nuit à la convergence rapide lors du fine-tuning de modèles pré-entraînés, sauf sur des entraînements plus longs.

Références

Sanh, V., Debut, L., Chaumond, J., & Wolf, T. (2019). DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. arXiv:1910.01108.

Keskar, N. S., et al. (2017). On Large-Batch Training for Deep Learning: Generalization Gap and Sharp Minima. ICLR 2017.

Sun, C., et al. (2019). How to Fine-Tune BERT for Text Classification. arXiv:1905.05583.

Foret, P., et al. (2021). Sharpness-Aware Minimization for Efficiently Improving Generalization. ICLR 2021.

Devlin, J., et al. (2018). BERT: Pre-training of Deep Bidirectional Transformers. arXiv:1810.04805.